

SISTEMA DISTRIBUIDO PARA ANÁLISIS DE SINIESTROS VIALES CON DATOS ABIERTOS DE INEGI

1. Descripción general

El proyecto propone el desarrollo de una plataforma de análisis distribuido de accidentes viales en México, utilizando Python, Ray y Ray Cluster. La aplicación procesará información histórica de accidentes de tránsito para identificar patrones de riesgo por entidad federativa, municipio, hora, mes, causa y gravedad del accidente.

2. Problema a resolver

Las instituciones públicas, municipios, escuelas de manejo, aseguradoras y áreas de movilidad urbana requieren analizar grandes volúmenes de datos de siniestralidad vial para apoyar la toma de decisiones. Cuando se acumulan datos históricos de varios años, el procesamiento secuencial puede volverse lento y limitado.

- Identificar municipios o zonas con mayor número de accidentes.
- Detectar horarios, días y meses con mayor riesgo.
- Analizar causas principales de accidentes.
- Relacionar accidentes con personas heridas y fallecidas.

3. Fuente de datos

La fuente sugerida es la estadística de Accidentes de Tránsito Terrestre en Zonas Urbanas y Suburbanas (ATUS) del INEGI. El dataset puede descargarse en formato CSV, Excel u otro formato disponible, y posteriormente convertirse a Parquet para mejorar la eficiencia de lectura y escritura.

Elemento	Descripción
Institución	INEGI
Dataset	Accidentes de Tránsito Terrestre en Zonas Urbanas y Suburbanas, ATUS
Unidad de análisis	Registro de accidente vial
Cobertura	Nacional, entidad federativa y municipio
Variables relevantes	Fecha, hora, entidad, municipio, causa, tipo de accidente, víctimas heridas y fallecidas
Formato de trabajo sugerido	Parquet para procesamiento distribuido

4. Objetivos del proyecto

Objetivo general

Diseñar e implementar una aplicación distribuida en Python usando Ray y Ray Cluster para procesar, analizar y visualizar patrones de accidentes viales a partir de datos abiertos del INEGI.


Objetivos específicos

1. Descargar o preparar los datos históricos de accidentes viales.
2. Limpiar, normalizar y transformar los registros usando Python.
3. Distribuir el procesamiento por entidad federativa, municipio, año, mes o bloques de registros.

- 4. Calcular estadísticas agregadas de accidentes, víctimas y causas.
- 5. Detectar patrones de riesgo por horario, causa, tipo de accidente y ubicación.
- 6. Generar reportes y visualizaciones para apoyar la interpretación de resultados.

5. Preguntas de análisis

Pregunta	Resultado esperado
¿Qué estados concentran más accidentes?	Ranking por entidad federativa
¿Qué municipios presentan mayor siniestralidad?	Tabla comparativa por municipio
¿En qué horarios ocurren más accidentes?	Distribución por hora del día
¿Qué causas son más frecuentes?	Ranking de causas
¿Qué meses presentan mayor incidencia?	Tendencia mensual
¿Dónde hay más víctimas heridas o fallecidas?	Análisis por zona y gravedad
¿Qué tan eficiente es Ray frente a Pandas secuencial?	Comparación de tiempos y speedup



Componente	Función principal
Fuente de datos ATUS	Provee los registros históricos de accidentes viales.
Módulo de limpieza	Estandariza columnas, tipos de datos, fechas, horas y valores faltantes.
Ray Head Node	Coordina el cluster, administra tareas, objetos y workers.
Ray Worker Nodes	Ejecutan tareas distribuidas sobre particiones de datos.
Dashboard o reporte	Presenta rankings, gráficas, indicadores y comparación de rendimiento.

6. Procesos distribuibles

Proceso	Forma de distribución
Limpieza de datos	Por bloques de registros o archivos.
Análisis por estado	Una tarea por entidad federativa.
Análisis por municipio	Múltiples tareas en paralelo.
Agregación mensual	Tareas por año o mes.
Detección de accidentes graves	Filtros distribuidos sobre bloques.
Calculo de indicadores	Reducción de resultados parciales.
Generación de reportes	Procesamiento por categoría o region.

7. Indicadores del sistema

Indicador	Descripción
Total de accidentes	Número total de registros analizados.
Accidentes con heridos	Accidentes donde hubo personas lesionadas.
Accidentes con fallecidos	Accidentes con víctimas mortales.
Accidentes por hora	Distribución de accidentes por hora del día.
Accidentes por municipio	Ranking municipal de siniestralidad.
Accidentes por causa	Causas mas frecuentes.
Accidentes por tipo	Colision, volcadura, atropellamiento u otros.
Indice de gravedad	Relacion entre accidentes, heridos y fallecidos.
Tendencia anual	Evolución histórica de la siniestralidad.

8. Productos

- Reporte técnico del proyecto.
- Dataset preparado en CSV o Parquet.
- Script con Ray
- Dashboard